
Texture Resonance Retrieval 的 NeurIPS 主会实验监督报告

基于 Audio-Agent 代码库的 formulation、实验设计与证据日志台账

Codex

2026-04-28

目录

第一章 摘要与监督结论	2
第二章 NeurIPS 主会目标：可执行音频效果参数检索	4
第三章 背景与相关工作定位	6
第四章 Formulation：检索式可编辑参数控制	8
第五章 方法：Texture Resonance Retrieval	11
第六章 NeurIPS 实验设计与评价方法	13
第七章 Logger 与证据台账规范	15
第八章 证据资产与归档结构	18
第九章 当前基线结果与统计证据	20
第十章 项目进度与 4-6 周监督计划	23
第十一章 KaiMing Gate：风险、验收与论文写作前置条件	25

第一章 摘要与监督结论

本报告将 Audio-Agent 当前代码库中的实验材料整理为一份学术论文式证据报告。报告的核心问题是：在可编辑音频效果参数控制任务中，基于二阶纹理统计的 Texture Resonance Retrieval (TRR) 是否比当前已评估的文本检索与音频嵌入检索基线更能找到参数空间上接近目标的可执行预设。本文结论限定于当前 guitar-effects 检索基准、当前数据切分和当前仓库产物下的检索式参数对齐证据；通用音频理解模型优越性和完整自动化音频系统端到端效果均不在本报告的证据范围内。

KaiMing 的当前监督判断是：本项目可以按照 NeurIPS main track 的方法论文路线继续推进，但目前还不能进入正式论文定稿阶段。可投叙事应收敛为“TRR 是一种面向可执行音频效果参数控制的 texture-aware second-order retrieval prior”，并避免扩展为通用音频表示学习、完整自动混音系统或端到端音频生成系统。论文写作必须等待三个前置项完成：formulation 冻结、4-6 周补实验完成、logger/evidence schema 能够把每一项主张映射到可复核 run artifact。

当前最强的主证据来自 resolved-audio-grouped Protocol-A。该协议在外部 1267 条 guitar-effects 数据集上，以 204 条测试查询和 1063 条知识库记录构成更严格的反泄漏切分，并以 top-1 检索输出的参数 JSON 作为评价对象。在该协议下，TRR 的平均参数距离为 8.0467，优于 Text-RAG 的 24.1705、Wav2Vec-RAG 的 23.8197、FeatureNN-RAG 的 19.2613，以及覆盖 201 条查询的 CLAP 基线 22.3102。TRR 同时在 Acc@0.1、Recall、Cosine 和 Module 指标上取得当前表格中的最好均值；bootstrap confidence intervals 与 Holm-corrected paired permutation tests 进一步支持这些比较。该结果支持的最强表述是：在当前已评估检索表示与当前严格切分下，TRR 是参数对齐最强的 retrieval prior。

报告同时纳入两个辅助证据层。Protocol-C 说明质量感知融合在 vague text 与 noisy audio 等单模态退化场景下可以退回到较可信模态；在 modality conflict 场景中，它仍显著弱于 TRR-only，因此该协议应被解释为边界条件诊断，而非现实鲁棒性证明。

Multiple-stimulus listening test 提供主观感知背景：26 名参与者产生 910 条评分，TRR-based system 在 Trials 2-5 中高于 manual baseline。该实验没有显式低质量 anchor，也缺少设备、专业程度与人工基线时间预算等元数据，因此不能被解释为严格的人机公平比较。

证据边界必须被显式保留。P0 E2/E3 报告与脚本来自 origin/master 的 80836fd 快照，但报告引用的 outputs/p0_e2 与 outputs/p0_e3_shared_e2_test 原始 CSV/JSON 当前不在 Git 文件树中，也不在本地 outputs 目录中。Protocol-B 已被标注为 deprecated，legacy retrieval report 也明确写有 do not cite in the TMM revision。因此，本报告将 P0 和 Protocol-B 视为历史线索或复现入口，而非正式主证据。

表 1.1: 本文证据层级与允许使用方式。

证据层	代表材料	允许结论
主证据	Protocol-A audio-grouped 统计与 per-query CSV	TRR 在当前严格检索基准中优于已评估检索基线。
辅助诊断	Protocol-C objective stats	Fusion 具有单模态 fallback 行为，但 conflict 失败必须披露。
主观背景	Listening test report	TRR-based system 具有一定主观感知参考价值，但不是严格人机公平胜负证据。
待补证据	P0 E2/E3 report and runbook	可作为复现入口；缺少原始 outputs 前不能作为正式结果引用。
历史材料	Protocol-B 与 legacy retrieval report	只能用于追溯叙事来源，不进入主结论。

表 1.1 是阅读本文的主要导航。后文首先定义任务和术语，再给出 TRR 方法、实验协议、实现路径、结果解释和风险边界。若读者只关心论文可写结论，应重点阅读第 九 章和第 十一 章；若读者需要复核代码与数据，应重点阅读第 七 章和第 十 章。

本轮更新之后，本文还承担一个监督台账功能：第 四 章冻结问题定义，第 六 章定义 NeurIPS 补实验矩阵，第 七 章定义 logger 与证据字段，第 十 章安排 4-6 周执行节奏，第 十一 章给出 KaiMing gate。后续正式论文应从这些 gate 通过后的证据表中抽取结果，而不应从未审计的中间输出中直接写 claim。

第二章 NeurIPS 主会目标：可执行音频效果参数检索

现代文本到音频与音乐生成模型通常直接输出波形。波形结果适合快速试听，但在专业音乐制作环境中并不天然满足可编辑性要求。制作人反复修改的对象是效果链、开关状态、阈值、增益、混响比例、延迟反馈和均衡曲线等可执行控制量。若系统只返回最终波形，用户很难把结果放回 Digital Audio Workstation (DAW) 中继续调节；若系统返回可执行参数，用户则可以在已有插件链路中检查、修改和复用结果。

面向 NeurIPS main track，本项目的学术入口应放在“可执行控制量的检索归纳偏置”上。它的研究价值来自一个清晰张力：通用音频语言模型擅长语义对齐，但可编辑效果参数要求系统在参数结构、模块开关和局部数值邻域上做出可复核选择。TRR 的潜在贡献是把深层音频特征的二阶纹理统计转化为这种检索归纳偏置。

表 2.1: NeurIPS main-track 定位边界。

维度	主文内定位	主文外边界
任务	retrieval-grounded editable audio effect control	通用音频生成或完整 DAW 代理。
输出	可执行参数 JSON 与候选预设	不可编辑的最终波形。
贡献	texture-aware second-order retrieval prior	通用音频语言模型或人类偏好模型。
评价	参数距离、配对统计、感知相关性补证	单次试听或未审计 demo。

表 2.1 给出本文后续写作的入口约束。它把主会叙事集中到可执行参数检索，避免把系统背景、产品链路和后续系统路线提前写成已验证贡献。

Audio-Agent 的研究对象正是这一类可编辑控制问题。给定文本意图和可选参考音频，系统希望从已有预设库中检索一个参数上可执行、听感上接近目标的候选预设。该任务与一

般语义检索不同，因为语义相似的描述不一定对应相似的效果参数；它也不同于直接参数回归，因为实际插件参数空间混合了连续值、离散开关和工程约束。一个保守而可验证的策略是将问题降为检索式参数对齐：先在有限数据库中找到相似原型，再把检索结果作为可编辑参数输出。

本报告关注的核心方法是 TRR。TRR 将音频表示为深层特征的 Gram 统计，用二阶通道共激活关系表达纹理结构，再用余弦相似度完成检索。与 mean-pooled Wav2Vec 这类一阶摘要相比，TRR 的假设是：许多吉他效果的可迁移信息不只存在于整体语义标签中，也存在于失真、调制、空间感和动态包络所形成的局部纹理统计中。该假设不意味着 TRR 是通用最优表示；它只说明，在当前参数检索任务上，二阶纹理统计可能比若干一阶或语义嵌入更贴近可执行参数邻域。

本文的贡献边界包括三个层面。本文将当前代码库中的主实验收敛到一个可审计证据链，其中 resolved-audio-grouped Protocol-A 是主要客观证据。本文还根据代码实现解释 TRR、文本检索、音频嵌入检索、质量感知融合和评价指标之间的关系。本文进一步明确标注尚不能支撑论文主张的材料，包括 P0 缺失原始输出、deprecated Protocol-B 和未完成的 PaSST/PANNs 结果。该边界使得报告主张更窄，但更容易被复核。

因此，本文不把 Audio-Agent 描述成已经完成验证的全栈音频智能体。更准确的定位是：Audio-Agent 当前代码库为 retrieval-grounded editable audio effect control 提供了一个实验性证据面，其中 TRR 是最有统计支持的核心检索表示，融合和端到端插件链路仍处于补充、诊断或探索阶段。

第三章 背景与相关工作定位

可编辑音频效果控制的难点来自一个非对称关系：用户通常用自然语言描述感知目标，例如 warm、tight、clean、heavy 或 ambient；插件实际执行的却是多模块参数向量。该向量包括压缩器、失真、过载、延迟、混响、合唱、镶边、均衡和相位等模块的开关状态与数值参数。自然语言、参考音频和参数向量之间没有一一对应关系，因此直接让语言模型生成参数容易出现数值漂移，直接使用通用音频嵌入也未必能对齐插件参数空间。

检索式方法为该问题提供了一个可审计中间层。系统不需要从零生成所有参数，而是在已有知识库中寻找相似预设，并输出该预设的真实参数。检索结果的优点是可执行、可检查、可复用；缺点是性能受数据库覆盖、切分质量和相似度定义限制。Audio-Agent 当前实验正是在这个折中点上展开：它评估不同检索表示是否能够更稳定地找到参数空间上接近 ground truth 的候选。

在当前代码库中，实验证据与产品链路应当分开理解。产品链路包含 DeepSeek 风格解析、MusicGen 音频生成、JUCE 插件参数导入与离线渲染；实验链路则主要围绕外部 1267 条 benchmark 数据、缓存向量和参数 JSON 展开。本文的主结论来自实验链路，尚未覆盖完整插件输出音频质量。这个区分很重要，因为参数空间评价能够支持 retrieval prior 的有效性，却不能自动证明端到端听感最优。

现有论文材料已经对主张进行了收敛。提交面文稿将主贡献限定为 retrieval-grounded editable preset control，并把 real-audio robustness 与端到端插件输出质量降级为探索或后续工作。本报告延续这一保守方向，并进一步将证据层分为 source claim、repo-observed fact、design intent 和 report synthesis。凡是只存在于计划、脚本或缺失输出报告中的内容，都不能被写成已经验证的事实。




图 3.1: 本文关注的检索式可编辑参数控制问题。主实验评价检索候选与 ground-truth 参数之间的距离，不直接评价最终波形质量。

图 3.1 展示了本文的研究边界。TRR 的角色是改善检索表示，使系统更可能从知识库中取回参数邻域正确的候选；它不是完整的 DAW 代理、不是端到端主观优化器，也不是替代所有音频表示的通用模型。

第四章 Formulation: 检索式可编辑参数控制

本文将一个效果预设表示为参数向量 θ 。在代码中, θ 表现为嵌套 JSON, 而非单纯的稠密向量; 叶子节点包含连续参数、字符串形式数值和模块开关状态。评价时, **Evaluator** 会递归展开数值叶子, 忽略无法转为数值的字符串, 并在缺失数值键时使用零补齐。因此, 本文中的参数距离表示当前实验代码定义的 flattened numeric parameter RMSE; 它不等同于感知距离或插件内部物理距离。

令 $q = (x, a)$ 表示一次查询, 其中 x 是文本描述, a 是可选参考音频或其缓存向量。令 $\mathcal{D} = \{(x_i, a_i, \theta_i)\}_{i=1}^N$ 表示预设知识库。检索方法学习或定义一个相似度函数 $s(q, i)$, 并返回

$$\hat{i} = \arg \max_i s(q, i), \quad \hat{\theta} = \theta_{\hat{i}}.$$

实验评价的核心对象是 $\hat{\theta}$ 与 held-out query 的 ground-truth 参数 θ^* 之间的差异。该形式化强调两个事实: 本文研究的是 retrieval prior, 范围不覆盖从零生成参数; 评价目标是参数对齐, 范围不覆盖完整听感偏好。

NeurIPS 主文中的问题定义应进一步固定为检索式可编辑参数控制。给定训练侧或知识库侧预设集合 $\mathcal{D}_{KB}$ 、测试侧查询集合 $\mathcal{D}_{test}$ 、查询输入 $q = (x, a)$ 和目标参数 θ^* , 方法 r_ϕ 直接输出可被插件或效果链执行的候选参数对象, 而非新生成波形:

$$r_\phi(q, \mathcal{D}_{KB}) \rightarrow (\hat{i}, \hat{\theta}, \hat{m}), \quad \hat{\theta} = \theta_{\hat{i}}.$$

其中 $\hat{m}$ 表示候选预设的模块结构或元数据。主风险函数定义为 held-out 查询上的期望参数误差

$$\mathcal{R}(r_\phi) = \mathbb{E}_{(q, \theta^*) \sim \mathcal{D}_{test}} \left[d(\hat{\theta}, \theta^*) \right],$$

其中 $d(\cdot, \cdot)$ 在当前代码中由 flattened numeric parameter RMSE、Acc@0.1、Recall、Cosine 和 Module consistency 共同操作化。该 formulation 的关键约束是 executable: 候选 $\hat{\theta}$ 必须来自真实预设或可被真实效果链加载的参数 JSON。这个约束区分了本文任务与纯文本到音频生成、纯 embedding retrieval、不可执行的风格标签分类。

因此, 主论文的中心假设可以写成以下可证伪命题: 在相同知识库、相同 held-out split 和相同参数距离定义下, 二阶纹理统计表示比一阶音频 embedding、文本/关键词匹配和通用音频语言 embedding 更适合检索可执行效果参数。若后续 PaSST、PANNs、direct regression 或 Text2FX-style optimization 在同一 logger schema 下超过 TRR, 该命题必须被削弱或重写。

表 4.1: 检索式可编辑参数控制的 formal contract。

对象	符号	本文约束
查询	$q = (x, a)$	文本描述与可选参考音频, 均可退化或缺失。
知识库	$\mathcal{D}_{KB}$	只包含可执行预设与可审计参数 JSON。
检索器	r_ϕ	输出候选索引、候选参数和候选模块元数据。
目标	θ^*	held-out query 的 ground-truth 参数。
风险	$\mathcal{R}(r_\phi)$	在测试查询上最小化参数空间距离。
证据	run artifact	每个主张必须绑定 split、checksum、per-query CSV 和统计检验。

表 4.1 将本节符号和后续实验台账连接起来。后续每个实验若改变输入、知识库、split 或风险定义, 都必须在 logger 中形成新的 run_id, 不能与既有主表混写。

TRR 指 Texture Resonance Retrieval。它在实验实现中优先读取 `item["Vectors"] ["TRR"]` 或 `<AudioPath>.trr.npy` 缓存, 只有缺失缓存时才懒加载 `TextureEncoder(project_dim=64)` 计算嵌入。检索时, TRR 对查询和数据库嵌入做 L2 归一化, 并以余弦相似度排序。该实现路径说明, 当前实验主要验证缓存 TRR 表示在既定数据集上的检索效果, 尚未验证在线特征提取系统的工程吞吐。

文本基线在报告中应谨慎命名。产品侧 RAG 使用 ChromaDB、SentenceTransformer、文本集合和参数集合; 但实验侧的 `RAGRetriever` 会将 SentenceTransformer monkey-patch 为随机 dummy embedding, 并在文本检索中实际使用 deterministic keyword overlap。因此, 实验中的 Text-RAG 更准确地说是轻量文本/关键词检索基线, 尚未构成完整语义向量 RAG 的强实现。

本文使用五个主要客观指标。Param. Dist. 是展开数值叶子后的 RMSE, 越低越好。Acc@0.1 是数值叶子处于绝对误差 0.1 内的比例, 越高越好。Recall 衡量激活参数的召回行为。Cosine 是展开参数向量的方向相似度。Module 是根据键名中 On/Off 模块状态推导的模块一致性。由于这些指标均来自当前代码的 operational definition, 跨协议比较绝对数值时必须谨慎; 同一协议内的配对比较更可靠。

最后, 本文使用 evidence boundary 指一个结论与其证据来源之间的匹配关系。如果某个结果有 CSV、JSON、统计报告和代码路径共同支撑, 它可以进入主证据链。如果某个结果只有报告文字而缺少原始输出, 或者来自 deprecated 文件, 它只能作为历史线索。这个规则贯穿本文所有结论。

第五章 方法：Texture Resonance Retrieval

TRR 的核心思想是用二阶统计描述音频纹理。给定深层音频特征矩阵 $\mathbf{H} \in \mathbb{R}^{C \times T}$ ，其中 C 表示通道维度， T 表示帧数，TRR 计算归一化 Gram 矩阵

$$\mathbf{G} = \frac{1}{T} \mathbf{H} \mathbf{H}^\top, \quad \mathbf{g} = \frac{\text{vec}(\mathbf{G})}{\|\text{vec}(\mathbf{G})\|_2}.$$

检索时，查询音频和数据库音频都被映射为 $\mathbf{g}$ ，然后用余弦相似度排序。该表示保留跨通道共激活结构，弱化绝对时间对齐；这与吉他效果中的失真颗粒、调制纹理、空间尾音和动态密度等现象相符，因为这些现象常表现为稳定纹理，而非某个精确时间点的瞬时事件。

与 mean pooling 相比，Gram 统计的优势在于它保留了通道之间的二阶关系。若两个音频片段在整体均值上相近，但一个包含更强的调制共振或失真相关结构，一阶摘要可能无法区分，而二阶统计可能改变其邻域排序。当前实验结果不能证明这个假设在所有音频任务上成立，但它支持该假设在 guitar-effects 参数检索任务上的有效性。




图 5.1: TRR 的计算路径。当前实验主要使用缓存 TRR 向量；缺失缓存时才懒加载编码器计算嵌入。

图 5.1 也说明了 TRR 的边界。TRR 只是检索表示，不负责生成新音频，也不直接修复插件参数。当前主实验的统计证据链只覆盖检索式参数对齐；未进入该证据链的系统探索不

应被写成已验证贡献。

Protocol-C 中的 fusion 方法属于辅助机制。它根据文本侧和音频侧 top-k 分数计算熵、质量分数和 audio bias，再输出 w_{text} 与 w_{audio} 。该机制的价值在于诊断输入退化时系统是否能选择更可靠的模态；它的局限也很明确：当文本与音频发生语义冲突时，当前融合规则仍可能偏离更低误差的 TRR-only 结果。因此，本文把 fusion 作为边界条件分析，不把它列为主方法。

第六章 NeurIPS 实验设计与评价方法

本章把当前实验协议升级为 NeurIPS main-track 的监督实验矩阵。核心原则是：每一个实验只服务一个可证伪命题，每一个主表数值都必须由 logger、原始输出、统计脚本和 checksum 共同支撑。现有 Protocol-A/Protocol-C 仍是基线证据，但它们只能证明“当前已评估检索基线下 TRR 有优势”；若要达到主会方法论文强度，还必须补齐强基线、消融、泄漏审计、真实鲁棒性和感知相关性。

表 6.1: NeurIPS main-track 补实验矩阵与 KaiMing 通过标准。

实验	目标命题	最小方法集合	主要指标	通过标准
E0 Evidence freeze	当前主证据可复核	Protocol-A 204, Protocol-C, listening test	checksum、run manifest、统计复现	所有主表文件可由 manifest 定位, checksum 通过。
E1 Strong baselines	排除弱 baseline 解释	Text, Wav2Vec, FeatureNN, CLAP, PaSST, PANNs, direct regression, Text2FX-style optimization	Param. Dist., Acc@0.1, Recall, Cosine, Module	同 split、同 query set、同 logger 下报告 CI 与 Holm-corrected tests。
E2 TRR ablation	二阶纹理统计是有效成分	mean pooling, Gram statistics, layer choice, projection dim, normalization, top-k aggregation	主指标加运行成本	至少一个结构性消融显著削弱主指标, 说明贡献不只是实现偶然性。
E3 Leakage and duplicate audit	结果不来自近重复泄漏	exact path, perceptual hash, embedding nearest-neighbor, family/group split	duplicate rate, performance under stricter split	更严格 split 下结论方向保持, 或明确降级 claim。
E4 Real robustness	排除 embedding-noise-only 解释	clean, SNR noise, EQ, compression, reverberation, codec	参数指标、fallback weight、失败类型	fusion/TRR 边界可解释; 不能只报告有利场景。
E5 Metric perception link	参数距离与听感有关系	objective metric vs listening score, rater metadata, anchor design	Spearman/Pearson, CI, inter-rater reliability	若相关性弱, 主文必须把指标定位为 controllability proxy。
E6 Submission package	可复现与匿名合规	code zip, data card, checklist, appendix, run scripts	checklist completeness, anonymous artifact audit	论文 claim、附录表、代码输出三者一一对应。

表 6.1 是后续 4–6 周的实验契约。该契约把当前最可辩护的研究对象压实为四个限定词：检索式、可执行、参数可编辑、证据可审计。凡是不能进入这个矩阵的探索，例如产品侧 UI 或端到端生成体验，都应保留在 future work 或系统背景中。

本报告采用三类协议口径。第一类是主证据协议，即 resolved-audio-grouped Protocol-A。该协议基于外部 1267 条 guitar-effects benchmark drop-in，按 resolved local audio path 分组后形成 204 条测试查询和 1063 条知识库记录，目的在于消除 legacy split 中已发现的 exact cross-split audio reuse。第二类是诊断协议，包括 211-query Protocol-C 和 legacy/strong-baseline 结果，用于分析融合边界和历史数值差异。第三类是待补协议，即 P0 E2/E3；它有报告和脚本，但缺少原始 outputs，因此不能作为主证据。

表 6.2: 实验协议、数据规模与证据状态。

协议或材料	测试数	知识库数	状态	本文用途
Protocol-A audio-grouped	204	1063	本地主统计与 per-query 结果存在	主证据，论文主表口径。
Protocol-A legacy/strong	211	1056	本地结果存在，但含 legacy split 风险	历史对照或诊断，不与 204 口径混写。
Protocol-C	211	1056	本地统计与 per-query 结果存在	Fusion fallback 与 conflict failure 诊断。
Listening test	26 participants	910 ratings	统计报告存在	主观补充，不作为严格胜负证据。
P0 E2/E3	204	1063	报告和脚本存在，原始 outputs 缺失	复现入口，不能作为正式主证据。
Protocol-B	211	1056	文件自标 deprecated	历史材料，不进入主结论。

表 6.2 中最重要的设计选择是把 204 条 audio-grouped Protocol-A 固定为主文口径。旧 211-query 结果在数值上更好看，例如 TRR 的 L2 为 0.3064，但该切分的 audit 发现 16 条跨 split shared resolved audio paths 和 48 对近重复风险。严格切分的 TRR L2 变为 8.0467，数值尺度明显不同，却更适合作为提交面主证据。因此，本文宁可使用较难、更保守的主表，也不将 legacy 数值当作核心结论。

每个检索方法输出一个候选参数 JSON。参数距离按展开后的数值叶子计算 RMSE; Acc@0.1、Recall、Cosine 和 Module 由 Experiments/common/evaluate.py 中的 Evaluator 实现。Protocol-A 统计报告使用 bootstrap confidence intervals 和 paired permutation tests，并用 Holm correction 处理多重比较。CLAP 在 audio-grouped 协议中只覆盖 201 条查询，因此与 TRR 的配对比较使用交集样本。

Protocol-C 的四个场景分别测试标准输入、vague text、noisy audio 和 modality conflict。需要强调的是，noisy audio 场景使用 embedding-space Gaussian noise，而非真实音频退化重新编码。因此，Protocol-C 只能说明当前 score-level fusion heuristic 的边界行为，不能证明系统已具备真实环境下的音频鲁棒性。

第七章 Logger 与证据台账规范

本章把代码实现路径进一步约束为可投稿证据路径。NeurIPS 主会论文不能只依赖“某个脚本曾经跑出过表格”；它需要每个结果都能回答四个问题：使用了哪一次运行，运行时仓库处于什么状态，输入数据和 split 的 checksum 是什么，统计检验如何从原始 per-query 结果生成。Logger 的职责就是把这些问题变成强制字段。

表 7.1: NeurIPS run logger 的最小字段规范。

字段	类型	角色	说明
<code>run_id</code>	string	主键	采用日期、实验编号、方法和短 hash 组成，所有 CSV/JSON/MD 共享。
<code>supervisor_gate</code>	enum	监督阶段	取值如 E0-freeze、E1-baseline、E2-ablation、E3-leakage。
<code>git_commit</code> <code>git_dirty</code>	/ string/bool	代码状态	记录 HEAD、branch、未提交变更摘要；dirty run 只能作探索，不能直接进入主表。
<code>command / env</code>	string/object	复现入口	保存完整命令、Python 版本、关键依赖版本、设备信息。
<code>dataset_checksum</code>	string	数据快照	指向 dataset manifest、split manifest 和原始 JSON/CSV checksum。
<code>split_id</code>	string	协议边界	明确 204 audio-grouped、legacy 211 或更严格 family split。
<code>query_count</code> <code>kb_count</code>	/ integer	规模审计	防止不同口径的样本规模被混入同一主表。
<code>method_config</code>	object	方法定义	保存 retriever、embedding、normalization、top-k、seed、ablation flags。
<code>metrics / stats</code>	object	统计结果	保存均值、CI、paired permutation、Holm correction 和有效样本交集。
<code>artifacts</code>	list	证据索引	列出 per-query CSV、summary JSON、stats MD、stderr/stdout 和 checksum。
<code>failure_flags</code>	list	负面证据	记录缺失缓存、跳过样本、异常输入、退化场景失败类型。

表 7.1 是后续实验代码需要满足的最小审计接口。它的主要作用是让论文表格、附录统计

和匿名代码包共享同一证据主键。

建议的运行产物目录为 `Experiments/NeurIPSRuns/<run_id>/`，其中至少包含 `run.json`、`per_query.csv`、`summary.json`、`stats.md`、`checksums.sha256` 和 `stdout.log`。本报告不声称该目录已经完全实现；它是从当前 evidence boundary 推导出的 design intent。后续实现时，旧的 Protocol-A/Protocol-C 产物可以被迁移或注册到同一 schema，而不需要重写历史结果。

KaiMing 对 logger 的验收标准很简单：任何进入主文的表格行，都必须能反查到唯一 `run_id`；任何显著性结论，都必须能反查到配对样本交集；任何缺失输出或 dirty run，都必须在表注或局限中被披露。若做不到这一点，该结果只能进入探索记录或附录待复现清单。

代码库中存在产品链路与实验链路两套路径。产品链路从用户文本和可选音频出发，通过 DeepSeek 解析风格与参数，经 `import_params.json` 传入 JUCE 插件，再由插件加载参数和音频并离线渲染。该链路说明 Audio-Agent 具备可执行插件控制的工程背景，但本文不把它作为主实验结果来源，因为主实验没有评价完整插件输出音频质量。

实验链路更适合作为论文证据。数据加载由 `Experiments/common/dataset_loader.py` 负责，优先读取外部 1267 条数据集 JSON，再回退到 repo 内 JSON 或 SQLite 合并。TRR 检索由 `Experiments/common/trr_adapter.py` 实现，优先使用缓存向量。直接检索比较由 `Experiments/AblationStudies/direct_retrieval_comparison.py` 驱动，Protocol-C 由 `Experiments/AblationStudies/robustness_test.py` 驱动，评价指标由 `Experiments/common/evaluate.py` 计算。




图 7.1: 实验证据生成路径。论文主结论应回到可复核的 CSV、JSON、Markdown 统计产物，避免依赖未验证的工程愿景。

图 7.1 对应当前最可靠的复现路径。对于 Protocol-A，复核者应从 split audit、audio-grouped per-query CSV 和 objective stats 开始，确认样本规模、指标定义和配对统计。对于 Protocol-C，复核者应检查每个 scenario 下 Text-only、TRR-only 和 Fusion 的 L2、权重均值及 Holm-corrected comparisons。对于 P0，复核者只能先阅读 runbook 和脚本，因为报告引用的原始 outputs 尚未提交。

当前代码中还存在一些不应被误写为主证据的部分。实验侧 Text-RAG 实际更接近 deterministic keyword overlap; Protocol-B 已经被标注为 deprecated; E0 合成音频管线仍有缺失音频记录。因此，本文在结论中使用“under the current held-out protocol”、“cached TRR representation”和“currently evaluated baselines”等限定语。

第八章 证据资产与归档结构

本次报告生成前,实验材料已经被整理到 `Experiments/AblationStudies/organized_experiment_data/`。该目录承担当前工作区可见材料的证据快照角色,不承担新的实验运行职责。它包含 `MANIFEST.csv`、`checksums.sha256`、P0 报告与脚本、Protocol A/B/C 结果、fusion beta sweep 以及 legacy retrieval report。所有归档文件都有 checksum, 便于后续判断内容是否被改动。

证据资产评价的关键是文件能够支持什么强度的结论。Protocol-A audio-grouped 的 CSV、JSON 和 Markdown 统计报告能够支撑当前主结果; Protocol-C 的 CSV/JSON/MD 能支撑 fallback 与 conflict failure 诊断; listening test 的统计报告能支撑主观补充分析; P0 报告缺少原始 outputs, 只能作为复现入口; Protocol-B 和 legacy report 明确不应进入主证据链。

表 8.1: 主要证据资产、来源状态与论文用途。

资产组	来源状态	论文用途
protocolA_audio_grouped_*	workspace untracked	主证据; 严格切分下 TRR 对比。
protocolA_*_with_clap*	workspace untracked	诊断或补充; 211-query 口径不得混入主表。
protocolC_*	workspace ignored	辅助诊断; 说明 fusion fallback 与 conflict failure。
results_report.md	workspace file	听测补充; 说明主观评分与统计限制。
P0_Experiments_Report.md	origin/master snapshot	复现入口; 缺少原始 outputs 前不能正式引用。
protocolB_*	workspace ignored	deprecated 历史材料。
retrieval_comparison_report.md	tracked legacy	追溯早期叙事, 不作为 TMM 主证据。

表 8.1 也解释了为什么本报告没有直接采用 P0 E2/E3 中 PaSST 与 PANNs 的数值。虽然 P0 报告给出了这些方法的 204-query 汇总, 但 `missing_outputs.md` 已确认对应的 `e2_summary.csv`、`e2_stats.json`、`e3_overall_summary.csv` 等原始文件缺失。学术论文可以引用报告作为待复现线索, 却不能把缺少原始产物的结果写成主表事实。

为了让后续写作不再次漂移, 建议将证据资产冻结为三个目录层级。第一层是主证据目录,

只包含 204 条 audio-grouped Protocol-A 结果和 split audit。第二层是诊断目录，包含 Protocol-C 和 listening test。第三层是历史与待补目录，包含 P0、Protocol-B 和 legacy retrieval report。这个结构有助于在写作中持续区分 repo-observed fact 与 design intent。

第九章 当前基线结果与统计证据

主实验结果见表 9.1。该表采用 resolved-audio-grouped Protocol-A，是本文推荐的主文口径，并报告每个方法在查询维度上的 bootstrap 95% confidence interval。TRR 在 204 条查询上取得最低参数距离 8.0467，并在 Acc@0.1、Recall、Cosine 和 Module 上取得最高均值。CLAP 覆盖 201 条查询，三个查询缺少可用缓存，因此其结果只与 TRR 在共享查询上配对比较。

表 9.1: Protocol-A audio-grouped 主结果。数值为 mean [95% CI]; Param. Dist. 越低越好，其余指标越高越好。

Method	n	Param. Dist.	Acc@0.1	Recall	Cosine	Module
TRR	204	8.0467 [5.7805, 10.4727]	0.5169 [0.4860, 0.5495]	0.4595 [0.4232, 0.4979]	0.8247 [0.7820, 0.8646]	0.8051 [0.7681, 0.8419]
Text-RAG	204	24.1705 [20.2018, 28.1073]	0.4717 [0.4371, 0.5073]	0.3967 [0.3592, 0.4353]	0.4943 [0.4314, 0.5596]	0.7456 [0.7108, 0.7809]
Wav2Vec-RAG	204	23.8197 [20.1623, 27.5540]	0.4251 [0.3925, 0.4596]	0.3505 [0.3130, 0.3893]	0.5292 [0.4663, 0.5902]	0.7043 [0.6668, 0.7411]
FeatureNN-RAG	204	19.2613 [15.9103, 22.7101]	0.4198 [0.3896, 0.4514]	0.3600 [0.3269, 0.3948]	0.5479 [0.4869, 0.6089]	0.7134 [0.6773, 0.7497]
CLAP	201	22.3102 [18.6405, 26.1201]	0.4492 [0.4167, 0.4821]	0.3971 [0.3615, 0.4329]	0.5725 [0.5133, 0.6317]	0.7240 [0.6884, 0.7591]

表 9.2 汇总 TRR 相对各 baseline 的 paired significance。对于 Param. Dist., Δ 定义为 baseline 减 TRR，正值表示 TRR 降低误差；对于其他指标， Δ 定义为 TRR 减 baseline，正值表示 TRR 提升指标。最后一列报告五个指标中最大的 Holm-corrected p 值，因此它是一个保守摘要：若该值小于 0.05，则 TRR 在五个客观指标上均通过 Holm 校正后的配对检验。

表 9.2: TRR 相对各 baseline 的 paired permutation significance 摘要。ΔL2 为 baseline-TRR；所有检验均使用 Holm correction。

Baseline	n	ΔL2 mean [95% CI]	$p_{\text{Holm}}(\text{L2})$	最大 p_{Holm} (五指标)
Text-RAG	204	16.1238 [12.3722, 19.8789]	0.0010	0.0227
Wav2Vec-RAG	204	15.7730 [12.2807, 19.3414]	0.0010	0.0010
FeatureNN-RAG	204	11.2146 [7.6011, 14.8710]	0.0010	0.0011
CLAP	201	14.1460 [10.3041, 18.0624]	0.0010	0.0181

表 9.1 与表 9.2 共同支持一个窄而强的结论：在当前严格切分和当前已评估检索基线中，TRR 是最强的参数对齐 retrieval prior。该结论不能外推为“TRR 是通用最优音频表示”。

外推边界来自三项事实。数据集是 guitar-effects 领域数据，不覆盖全部音频任务。评价指标是参数空间 operational metrics，不能直接替代听感距离。PaSST、PANNs 和直接参数回归在当前可复核主证据中尚未完成。

Protocol-C 的结果见表 9.3。在 standard 场景，Fusion L2 为 0.3056，接近但略差于 TRR-only 的 0.2970。在 vague text 场景，Fusion 完全退回音频侧，等同 TRR-only。在 noisy audio 场景，Fusion 完全退回文本侧，避免了 TRR-only 在 embedding-space noise 下的崩溃。在 conflict 场景，Fusion 虽然优于 Text-only，但显著弱于 TRR-only。这说明当前 fusion heuristic 有可解释 fallback 行为，也有明确 failure mode。

表 9.3: Protocol-C 边界条件结果。权重均值来自 Fusion 分支；该协议使用 embedding-space noise，因此只作为诊断。

Scenario	$\mathbb{E}[w_{\text{text}}]$	$\mathbb{E}[w_{\text{audio}}]$	Text-only L2	TRR-only L2	Fusion L2
Standard	0.4716	0.5284	1.5148	0.2970	0.3056
Vague text	0.0000	1.0000	12.6517	0.2970	0.2970
Noisy audio	1.0000	0.0000	1.5148	33.8549	1.5148
Conflict	0.4123	0.5877	12.8572	0.2970	4.5259

听测结果见表 9.4。Trials 2–5 中，TRR-based system 的主观评分高于 manual baseline；Trials 6–10 中，MusicGen 与 TRR-based system 的差异没有达到统计显著。由于该实验没有显式低质量 anchor，也缺少设备、参与者专业程度和人工基线时间预算等元数据，本文将解释为 workflow relevance 的主观背景，不将其写成系统优于人工或优于生成模型的

强结论。

表 9.4: Multiple-stimulus listening test 摘要。原始日志标签 HCAP 在论文叙述中对应 TRR-based system。

Block	Comparison	n	Mean(A-B)	rbc	p (Holm)
Trials 2–5	reference vs TRR-based system	26	13.78	0.860	0.00015
Trials 2–5	TRR-based system vs manual	26	19.83	1.000	0.00015
Trials 6–10	reference vs TRR-based system	26	46.71	0.994	0.00015
Trials 6–10	MusicGen vs TRR-based system	24	-1.10	0.067	0.7797

综合来看，当前证据支持的论文叙事应当以 Protocol-A 为中心，以 Protocol-C 说明方法边界，以听测说明用户感知背景。P0 中包含更丰富的 SOTA baseline 叙述，但缺少原始 outputs；因此它在现阶段不能替代表 9.1 成为主结果表。

第十章项目进度与 4-6 周监督计划

截至 2026-04-28，本报告对应的仓库状态是一个实验材料充足但工作区较脏的研究工作区。已经完成的部分包括：实验数据归档目录已创建，manifest 与 checksum 已生成并通过校验；报告工作区已初始化并渲染；Protocol-A、Protocol-C 和听测统计均有本地可读产物；远端 origin/master 的 P0 报告与脚本已被抽取到归档目录；主结果表已经升级为带 bootstrap confidence intervals 与 paired significance 的论文表。尚未完成的部分包括：P0 原始 outputs 未找回；Protocol-A 多个口径尚需冻结；归档目录和报告目录仍未 stage；部分实验结果文件处于 ignored 或 untracked 状态；NeurIPS 补实验的统一 logger schema 尚未实现。

表 10.1: 当前项目进度与证据状态。

事项	当前状态	下一步
实验归档目录	已生成，checksum 通过	决定是否纳入版本控制。
报告工作区	已生成并写入学术论文式正文	继续审阅并按需要修订。
Protocol-A 主证据	204 条 audio-grouped 结果存在	冻结为唯一主文口径。
主结果统计表	已补 mean [95% CI] 与 Holm-corrected paired tests	与 logger run id 绑定。
Protocol-C 诊断	211 条边界条件结果存在	保留 conflict failure 表述。
听测统计	26 participants / 910 ratings 报告存在	继续作为主观补充，避免强外推。
P0 E2/E3	报告和脚本存在，原始 outputs 缺失	找回或按 runbook 复现。
Protocol-B 与 legacy report	已降级为历史材料	不进入主论文证据链。

表 10.2: 4-6 周 NeurIPS main-track 执行节奏。

周次	KaiMing gate	预期产物	不通过时的处理
Week 1	Evidence freeze	canonical manifest, checksums, 204 split lock, logger schema v0	不写新 claim, 先修证据台账。
Week 2	Strong baseline parity	PaSST、PANNs、direct regression、Text2FX-style baseline 的同口径结果	若任一强基线缺失, 主文表标记为 incomplete。
Week 3	TRR ablation	Gram/mean/layer/projection/normalization/消融表	若消融不能解释优势, 方法贡献降级为 empirical observation。
Week 4	Leakage and robustness	near-duplicate audit、真实音频退化 E3、失败类型清单	若严格 split 下优势消失, 重新定义任务或 claim。
Week 5	Metric-perception link	objective-listening correlation、anchor/rater metadata、附录统计	若相关性弱, 主文把参数距离限定为 controllability proxy。
Week 6	Submission freeze	anonymized code/data package、checklist、appendix、paper table lock	未通过则进入 workshop/technical report 路线。

表 10.1 中最需要优先处理的是 P0、主证据冻结和 logger schema。若目标是正式投稿, 建议先把 204 条 audio-grouped Protocol-A、Protocol-C 和 listening test 的 canonical 文件纳入一个干净分支, 并在 README 或 manifest 中记录生成命令、数据集快照、统计方法和校验和。只有当 P0 原始 CSV/JSON 被找回或复现后, P0 中的 PaSST/PANNs 与真实退化 E3 结果才适合进入正式论文表格。表 10.2 给出的节奏属于监督计划, 尚未构成已完成 repo fact; 每周结束必须用 logger artifact 与统计报告更新本章。

当前报告本身也应视为 single-source working report。它已经根据现有代码和实验产物生成正文, 并开始承担 supervisor ledger 的职责, 但仍需要人工做三类审阅。第一类是科学审阅, 确认是否接受“TRR 是当前已评估 retrieval prior 中最强”这一保守主张。第二类是证据审阅, 确认所有主表数值是否应以 audio-grouped 204 口径为唯一来源, 并决定是否将 211 口径全部移入附录或历史说明。第三类是投稿审阅, 确认 NeurIPS main track 的 baseline、消融、复现、匿名代码和 checklist 是否满足主会标准。

第十一章 KaiMing Gate: 风险、验收与论文写作前置条件

本文的主要结论是保守的。TRR 在当前 guitar-effects、resolved-audio-grouped、retrieval-only benchmark 上, 是已评估检索表示中参数对齐最强的 retrieval prior。该结论由 204 条测试查询、1063 条知识库记录、CLAP 共享查询、bootstrap confidence intervals 和 paired permutation tests 支撑。它足以构成一篇围绕 retrieval-grounded editable audio effect control 的方法与实验证据报告, 但不足以支撑通用音频表示、端到端主观质量或完整自动化音频系统的强 claim。

KaiMing gate 用于防止论文在证据尚未闭合时提前固化。当前阶段允许撰写 abstract sketch、method skeleton、experiment checklist 和 appendix template; 不允许锁定 NeurIPS 主表、正式 conclusion 或强 novelty claim。主论文启动条件应由表 11.1 控制。

表 11.1: KaiMing gate 与论文写作前置条件。

Gate	必须通过的证据	失败时的论文处理	状态
Formulation gate	任务、输入、输出、risk、指标和 executable constraint 已在报告中冻结	回到问题定义, 不写 introduction claim	已写入本报告, 待审阅。
Baseline gate	PaSST、PANNs、direct regression、Text2FX-style baseline 与 TRR 同口径比较	主表不能声称 SOTA-level superiority	待实验。
Ablation gate	二阶纹理统计、层选择、归一化和 top-k 设计有可解释贡献	方法贡献降级为经验性检索特征	待实验。
Leakage gate	exact duplicate、near duplicate 和 family split 风险已审计	降低 claim 或更换主协议	部分完成。
Robustness gate	真实音频退化与 conflict 场景均披露正负结果	鲁棒性只写为边界诊断	待实验。
Perception gate	参数指标与听感评分关系已估计, 或明确证明相关性不足	参数指标限定为 controllability proxy	待实验。
Reproducibility gate	logger、checksum、run scripts、anonymous package 和 checklist 对齐	只能作为内部报告或 workshop draft	待实现。

第一个局限是数据域。当前 benchmark 主要围绕吉他效果预设展开，参数结构也绑定于特定效果链。TRR 对该域有效，并不自动意味着它对鼓组、人声、混音母带或开放世界音频编辑同样有效。第二个局限是指标。Param. Dist.、Acc@0.1、Recall、Cosine 和 Module 都是参数空间指标，不能完全替代听感距离。第三个局限是协议。严格 split 已消除 exact resolved-audio reuse，但 near-duplicate 风险仍需更强审计。第四个局限是工程证据。产品链路存在，但主实验没有直接评价完整插件输出音频。

第二个需要明确的风险是融合边界。Protocol-C 说明 fusion 可以在单模态退化时退回到较可信模态，但 conflict 场景中的 Fusion L2=4.5259 远高于 TRR-only 的 0.2970，说明当前融合规则仍无法可靠处理相互矛盾的文本与音频输入。若后续要扩展融合主张，必须新增独立协议，定义冲突输入、真实退化、失败类型和统计检验。

表 11.2: 主张、证据与允许措辞矩阵。

主张	证据状态	允许措辞
TRR 优于当前已评估检索基线	204 audio-grouped Protocol-A 支撑	可以作为主结论。
TRR 是通用最优音频表示	无跨域证据	不应声称。
Fusion 具备 fallback 行为	Protocol-C 支撑	可作为诊断结论。
Fusion 全面优于 TRR-only	conflict 场景反证	不应声称。
TRR-based system 有主观感知价值	听测补充支持	可保守表述为主观背景。
系统严格优于人工调参或 MusicGen	元数据与统计边界不足	不应声称。
P0 PaSST/PANNs 已正式验证	原始 outputs 缺失	只能作为待复现线索。

表 11.2 是本文最终结论的约束条件。后续交付应按三个优先级推进。首先，冻结主证据：将 204 条 audio-grouped Protocol-A、Protocol-C 和 listening test 作为 canonical artifacts，明确路径、命令和 checksum。其次，补齐 P0：找回或复现 P0 E2/E3 outputs，若无法补齐，则不要把 P0 数值并入主文。最后，扩展实验：若要主张真实鲁棒性或端到端听感优势，需要新增真实音频退化和插件输出音频的独立协议。

在当前证据条件下，最合适的论文式结论是：TRR 将深层音频特征的二阶纹理统计用于可执行音频效果参数检索，在当前严格 guitar-effects 检索基准中，相比文本、Wav2Vec、FeatureNN 和 CLAP 等已评估基线表现出更好的参数对齐。该结论窄而可审计，是继续推进正式论文、复现实验和后续系统验证的合理基础。

因此，本报告对下一阶段的监督结论是：先执行 E0–E6，边做实验边更新本报告；当表 11.1 至少通过 formulation、baseline、ablation、leakage 和 reproducibility 五项后，再启动正式

NeurIPS manuscript drafting。若 4-6 周内无法通过 baseline 或 leakage gate, 项目仍然可以形成严谨的 technical report, 但不应以 NeurIPS main-track 强贡献论文为目标提交。