
Texture Resonance Retrieval 的 TMM 期刊证据监督报告

基于 Audio-Agent 代码库的 claim gate、submission package 与可复
现实验台账

Codex

2026-04-28

目录

第一章 摘要与监督结论	2
第二章 TMM 期刊目标：可执行音频效果参数检索	4
第三章 背景与相关工作定位	6
第四章 Formulation：检索式可编辑参数控制	8
第五章 方法：Texture Resonance Retrieval	11
第六章 TMM 实验设计与评价方法	13
第七章 TMM 可复现台账与证据包规范	16
第八章 证据资产与归档结构	19
第九章 当前基线结果与统计证据	21
第十章 项目进度与 TMM 提交包收束计划	24
第十一章 KaiMing Gate：TMM 风险、验收与论文写作前置条件	26

第一章 摘要与监督结论

本报告将 Audio-Agent 当前代码库中的实验材料整理为一份学术论文式证据报告。报告的核心问题是：在可编辑音频效果参数控制任务中，基于二阶纹理统计的 Texture Resonance Retrieval (TRR) 是否比当前已评估的文本检索与音频嵌入检索基线更能找到参数空间上接近目标的可执行预设。本文结论限定于当前 guitar-effects 检索基准、当前数据切分和当前仓库产物下的检索式参数对齐证据；通用音频理解模型优越性和完整自动化音频系统端到端效果均不在本报告的证据范围内。

KaiMing 的当前监督判断是：本项目应从 NeurIPS 主会监督路线转向 TMM 期刊修订路线。可投叙事仍应收敛为“TRR 是一种面向可执行音频效果参数控制的 texture-aware second-order retrieval prior”，但验收标准应改为 TMM 期刊证据闭合：主文、补充材料、response letter 和匿名可复现包必须共享同一组 canonical artifacts；每个核心 claim 必须能够反查到 split、checksum、命令、per-query CSV、统计脚本和局限说明；页数、supplement、图表、citation 与 response hygiene 必须先于新增大规模实验完成。

当前最强的主证据来自 P0 E2/E3。P0 E2 在外部 1267 条 guitar-effects 数据集上，以 204 条测试查询和 1063 条知识库记录构成共享 Protocol-A baseline matrix，并以 top-1 检索输出的参数 JSON 作为评价对象。在该协议下，TRR 的 L2 为 8.7287，Norm.L2 为 0.1881，优于 Wav2Vec、FeatureNN、CLAP、PaSST 和 PANNs；TRR 同时在 Acc@0.1、Recall、Cosine 和 Module 指标上取得当前表格中的最好均值。基于 per-query Norm.L2 的 Wilcoxon + Holm 检验拒绝 TRR 与每个 baseline 无差异的原假设，但效应量较小。因此，该结果支持的最强表述是：在当前 P0 已评估检索表示下，TRR 是参数对齐最强且统计可靠但幅度适中的 retrieval prior。

报告同时纳入两个辅助证据层。P0 E3 对原始音频施加 AWGN、MP3、reverb 和 truncate 退化后重新编码，说明真实退化下 audio-heavy fusion 明显脆弱，而 adaptive fusion 在总体 L2、Acc@0.1、MRR 和 NDCG@5 上略优于固定 a0.50 / a0.70，并接近稳定的中高文

本权重工作区间。旧 Protocol-C 的 embedding-space 退化结果仍可作为历史诊断，但不再是鲁棒性主证据。

Multiple-stimulus listening test 提供主观感知背景：26 名参与者产生 910 条评分，TRR-based system 在 Trials 2–5 中高于 manual baseline。该实验没有显式低质量 anchor，也缺少设备、专业程度与人工基线时间预算等元数据，因此不能被解释为严格的人机公平比较。

证据边界必须被显式保留。用户已 double check P0 E2/E3 原始数据的真实性、完整性与正确性，因此本轮写作将 P0 数值作为正式实验结果写入论文主结果。Protocol-B 已被标注为 deprecated，legacy retrieval report 也明确写有 do not cite in the TMM revision，因此仍不能进入主结论。

表 1.1: 本文证据层级与允许使用方式。

证据层	代表材料	允许结论
主证据	P0 E2 verified experimental data	TRR 在当前 P0 baseline matrix 中优于已评估检索基线。
鲁棒性证据	P0 E3 verified experimental data	Adaptive fusion 在真实退化下优于低文本权重固定融合，并接近稳定工作区间。
主观背景	Listening test report	TRR-based system 具有一定主观感知参考价值，但不是严格人机公平胜负证据。
待补证据	Direct regression / reranker / 跨域实验	只能作为 future work，不进入当前主结论。
历史材料	Protocol-B 与 legacy retrieval report	只能用于追溯叙事来源，不进入主结论。

表 1.1 是阅读本文的主要导航。后文首先定义任务和术语，再给出 TRR 方法、实验协议、实现路径、结果解释和风险边界。若读者只关心论文可写结论，应重点阅读第 九 章和第 十 一章；若读者需要复核代码与数据，应重点阅读第 七 章和第 十 一章。

本轮更新之后，本文还承担一个监督台账功能：第 四 章冻结问题定义，第 六 章定义 TMM 证据矩阵，第 七 章定义 logger 与证据字段，第 十 章安排 TMM 提交包收束节奏，第 十 一章给出 KaiMing gate。后续正式论文应从这些 gate 通过后的证据表中抽取结果，而不应从未审计的中间输出中直接写 claim。

第二章 TMM 期刊目标：可执行音频效果参数检索

现代文本到音频与音乐生成模型通常直接输出波形。波形结果适合快速试听，但在专业音乐制作环境中并不天然满足可编辑性要求。制作人反复修改的对象是效果链、开关状态、阈值、增益、混响比例、延迟反馈和均衡曲线等可执行控制量。若系统只返回最终波形，用户很难把结果放回 Digital Audio Workstation (DAW) 中继续调节；若系统返回可执行参数，用户则可以在已有插件链路中检查、修改和复用结果。

面向 IEEE Transactions on Multimedia，本项目的学术入口应放在“多媒体信号处理与系统集成场景中的可执行参数检索”上。TMM 关注 multimedia technology and applications，包括 signal processing、systems、software 与 systems integration；因此，本文不能只讲一个聪明的 embedding，也不能把产品代理愿景当作主贡献。TRR 的 TMM 价值在于：它把音频纹理的二阶统计转化为可编辑效果参数检索的可审计 prior，并把检索结果落到真实可执行预设，而不是不可编辑的最终波形。

表 2.1: TMM 期刊定位边界。

维度	主文内定位	主文外边界
任务	可编辑效果参数检索	通用音频生成或完整 DAW 代理。
输出	可执行参数 JSON 与候选预设	不可编辑的最终波形。
贡献	二阶纹理检索先验	通用音频语言模型或人类偏好模型。
评价	参数距离、配对统计、感知相关性补证	单次试听或未审计 demo。
提交包	主文、附录、答复与证据包一致	未绑定证据的叙事性 claim。

表 2.1 给出本文后续写作的入口约束。它把 TMM 期刊叙事集中到可执行参数检索，避免

把系统背景、产品链路和后续系统路线提前写成已验证贡献。

Audio-Agent 的研究对象正是这一类可编辑控制问题。给定文本意图和可选参考音频，系统希望从已有预设库中检索一个参数上可执行、听感上接近目标的候选预设。该任务与一般语义检索不同，因为语义相似的描述不一定对应相似的效果参数；它也不同于直接参数回归，因为实际插件参数空间混合了连续值、离散开关和工程约束。一个保守而可验证的策略是将问题降为检索式参数对齐：先在有限数据库中找到相似原型，再把检索结果作为可编辑参数输出。

本报告关注的核心方法是 TRR。TRR 将音频表示为深层特征的 Gram 统计，用二阶通道共激活关系表达纹理结构，再用余弦相似度完成检索。与 mean-pooled Wav2Vec 这类一阶摘要相比，TRR 的假设是：许多吉他效果的可迁移信息不只存在于整体语义标签中，也存在于失真、调制、空间感和动态包络所形成的局部纹理统计中。该假设不意味着 TRR 是通用最优表示；它只说明，在当前参数检索任务上，二阶纹理统计可能比若干一阶或语义嵌入更贴近可执行参数邻域。

本文的贡献边界包括三个层面。本文将当前代码库中的主实验收敛到一个可审计证据链，其中 P0 E2 是主要客观检索证据，P0 E3 是真实退化下的 fusion robustness 证据。本文还根据代码实现解释 TRR、文本检索、音频嵌入检索、质量感知融合和评价指标之间的关系。本文进一步明确标注尚不能支撑论文主张的材料，包括 deprecated Protocol-B、direct regression、learned reranker 和跨域鲁棒性结果。该边界使得报告主张更强但仍可复核。

因此，本文不把 Audio-Agent 描述成已经完成验证的全栈音频智能体。更准确的定位是：Audio-Agent 当前代码库为 retrieval-grounded editable audio effect control 提供了一个实验性证据面，其中 TRR 是最有统计支持的核心检索表示，融合和端到端插件链路仍处于补充、诊断或探索阶段。

第三章 背景与相关工作定位

可编辑音频效果控制的难点来自一个非对称关系：用户通常用自然语言描述感知目标，例如 warm、tight、clean、heavy 或 ambient；插件实际执行的却是多模块参数向量。该向量包括压缩器、失真、过载、延迟、混响、合唱、镶边、均衡和相位等模块的开关状态与数值参数。自然语言、参考音频和参数向量之间没有一一对应关系，因此直接让语言模型生成参数容易出现数值漂移，直接使用通用音频嵌入也未必能对齐插件参数空间。

检索式方法为该问题提供了一个可审计中间层。系统不需要从零生成所有参数，而是在已有知识库中寻找相似预设，并输出该预设的真实参数。检索结果的优点是可执行、可检查、可复用；缺点是性能受数据库覆盖、切分质量和相似度定义限制。Audio-Agent 当前实验正是在这个折中点上展开：它评估不同检索表示是否能够更稳定地找到参数空间上接近 ground truth 的候选。

在当前代码库中，实验证据与产品链路应当分开理解。产品链路包含 DeepSeek 风格解析、MusicGen 音频生成、JUICE 插件参数导入与离线渲染；实验链路则主要围绕外部 1267 条 benchmark 数据、缓存向量和参数 JSON 展开。本文的主结论来自实验链路，尚未覆盖完整插件输出音频质量。这个区分很重要，因为参数空间评价能够支持 retrieval prior 的有效性，却不能自动证明端到端听感最优。

现有论文材料已经对主张进行了收敛。提交面文稿将主贡献限定为 retrieval-grounded editable preset control，并在本轮根据用户已 double check 的 P0 E3 结果，把 real-audio degradation robustness 从“待补实验”升级为“当前退化集合下的 fusion 证据”。本报告仍将证据层分为 source claim、repo-observed fact、已确认正式实验数据、design intent 和 report synthesis。凡是只存在于计划或脚本中的内容，仍不能被写成已经验证的事实；P0 E2/E3 则按已确认真实、完整、正确的正式实验数据处理。




图 3.1: 本文关注的检索式可编辑参数控制问题。主实验评价检索候选与 ground-truth 参数之间的距离，不直接评价最终波形质量。

图 3.1 展示了本文的研究边界。TRR 的角色是改善检索表示，使系统更可能从知识库中取回参数邻域正确的候选；它不是完整的 DAW 代理、不是端到端主观优化器，也不是替代所有音频表示的通用模型。

第四章 Formulation: 检索式可编辑参数控制

本文将一个效果预设表示为参数向量 θ 。在代码中, θ 表现为嵌套 JSON, 而非单纯的稠密向量; 叶子节点包含连续参数、字符串形式数值和模块开关状态。评价时, **Evaluator** 会递归展开数值叶子, 忽略无法转为数值的字符串, 并在缺失数值键时使用零补齐。因此, 本文中的参数距离表示当前实验代码定义的 flattened numeric parameter RMSE; 它不等同于感知距离或插件内部物理距离。

令 $q = (x, a)$ 表示一次查询, 其中 x 是文本描述, a 是可选参考音频或其缓存向量。令 $\mathcal{D} = \{(x_i, a_i, \theta_i)\}_{i=1}^N$ 表示预设知识库。检索方法学习或定义一个相似度函数 $s(q, i)$, 并返回

$$\hat{i} = \arg \max_i s(q, i), \quad \hat{\theta} = \theta_{\hat{i}}.$$

实验评价的核心对象是 $\hat{\theta}$ 与 held-out query 的 ground-truth 参数 θ^* 之间的差异。该形式化强调两个事实: 本文研究的是 retrieval prior, 范围不覆盖从零生成参数; 评价目标是参数对齐, 范围不覆盖完整听感偏好。

TMM 期刊主文中的问题定义应进一步固定为检索式可编辑参数控制。给定训练侧或知识库侧预设集合 $\mathcal{D}_{KB}$ 、测试侧查询集合 $\mathcal{D}_{test}$ 、查询输入 $q = (x, a)$ 和目标参数 θ^* , 方法 r_ϕ 直接输出可被插件或效果链执行的候选参数对象, 而非新生成波形:

$$r_\phi(q, \mathcal{D}_{KB}) \rightarrow (\hat{i}, \hat{\theta}, \hat{m}), \quad \hat{\theta} = \theta_{\hat{i}}.$$

其中 $\hat{m}$ 表示候选预设的模块结构或元数据。主风险函数定义为 held-out 查询上的期望参数误差

$$\mathcal{R}(r_\phi) = \mathbb{E}_{(q, \theta^*) \sim \mathcal{D}_{test}} \left[d(\hat{\theta}, \theta^*) \right],$$

其中 $d(\cdot, \cdot)$ 在当前代码中由 flattened numeric parameter RMSE、Acc@0.1、Recall、Cosine 和 Module consistency 共同操作化。该 formulation 的关键约束是 executable: 候选 $\hat{\theta}$ 必须来自真实预设或可被真实效果链加载的参数 JSON。这个约束区分了本文任务与纯文本到音频生成、纯 embedding retrieval、不可执行的风格标签分类。

因此, 主论文的中心假设可以写成以下可证伪命题: 在相同知识库、相同 held-out split 和相同参数距离定义下, 二阶纹理统计表示比一阶音频 embedding、文本/关键词匹配和通用音频语言 embedding 更适合检索可执行效果参数。P0 E2 已将 PaSST 与 PANNs 纳入该命题的当前证据面; 若后续 direct regression、learned reranker 或 Text2FX-style optimization 在同一 logger schema 下超过 TRR, 该命题必须被削弱或重写。

表 4.1: 检索式可编辑参数控制的 formal contract。

对象	符号	本文约束
查询	$q = (x, a)$	文本描述与可选参考音频, 均可退化或缺失。
知识库	$\mathcal{D}_{KB}$	只包含可执行预设与可审计参数 JSON。
检索器	r_ϕ	输出候选索引、候选参数和候选模块元数据。
目标	θ^*	held-out query 的 ground-truth 参数。
风险	$\mathcal{R}(r_\phi)$	在测试查询上最小化参数空间距离。
证据	run artifact	每个主张必须绑定 split、checksum、per-query CSV 和统计检验。

表 4.1 将本节符号和后续实验台账连接起来。后续每个实验若改变输入、知识库、split 或风险定义, 都必须在 logger 中形成新的 run_id, 不能与既有主表混写。

TRR 指 Texture Resonance Retrieval。它在实验实现中优先读取记录内的 TRR 向量或音频旁路缓存, 只有缺失缓存时才懒加载 TextureEncoder 计算嵌入。检索时, TRR 对查询和数据库嵌入做 L2 归一化, 并以余弦相似度排序。该实现路径说明, 当前实验主要验证缓存 TRR 表示在既定数据集上的检索效果, 尚未验证在线特征提取系统的工程吞吐。

文本基线在报告中应谨慎命名。产品侧 RAG 使用 ChromaDB、SentenceTransformer、文本集合和参数集合; 但实验侧的 RAGRetriever 会将 SentenceTransformer monkey-patch 为随机 dummy embedding, 并在文本检索中实际使用 deterministic keyword overlap。因此, 实验中的 Text-RAG 更准确地说是轻量文本/关键词检索基线, 尚未构成完整语义向量 RAG 的强实现。

本文使用五个主要客观指标: 参数距离、阈值准确率、召回、余弦相似度与模块一致性。参

数距离对应展开数值叶子的 RMSE, 越低越好; 阈值准确率对应绝对误差 0.1 内的比例, 越高越好; 其余三项分别衡量激活参数召回、方向相似度和 On/Off 状态一致性。由于这些指标均来自当前代码的 operational definition, 跨协议比较绝对数值时必须谨慎; 同一协议内的配对比较更可靠。

最后, 本文使用 evidence boundary 指一个结论与其证据来源之间的匹配关系。如果某个结果有原始输出、统计报告、脚本路径或用户已 double check 的完整实验记录共同支撑, 它可以进入主证据链。如果某个结果未经验证、只有计划文字, 或者来自 deprecated 文件, 它只能作为历史线索。这个规则贯穿本文所有结论。

第五章 方法：Texture Resonance Retrieval

TRR 的核心思想是用二阶统计描述音频纹理。给定深层音频特征矩阵 $\mathbf{H} \in \mathbb{R}^{C \times T}$ ，其中 C 表示通道维度， T 表示帧数，TRR 计算归一化 Gram 矩阵

$$\mathbf{G} = \frac{1}{T} \mathbf{H} \mathbf{H}^\top, \quad \mathbf{g} = \frac{\text{vec}(\mathbf{G})}{\|\text{vec}(\mathbf{G})\|_2}.$$

检索时，查询音频和数据库音频都被映射为 $\mathbf{g}$ ，然后用余弦相似度排序。该表示保留跨通道共激活结构，弱化绝对时间对齐；这与吉他效果中的失真颗粒、调制纹理、空间尾音和动态密度等现象相符，因为这些现象常表现为稳定纹理，而非某个精确时间点的瞬时事件。

与 mean pooling 相比，Gram 统计的优势在于它保留了通道之间的二阶关系。若两个音频片段在整体均值上相近，但一个包含更强的调制共振或失真相关结构，一阶摘要可能无法区分，而二阶统计可能改变其邻域排序。当前实验结果不能证明这个假设在所有音频任务上成立，但它支持该假设在 guitar-effects 参数检索任务上的有效性。




图 5.1: TRR 的计算路径。当前实验主要使用缓存 TRR 向量；缺失缓存时才懒加载编码器计算嵌入。

图 5.1 也说明了 TRR 的边界。TRR 只是检索表示，不负责生成新音频，也不直接修复插件参数。当前主实验的统计证据链只覆盖检索式参数对齐；未进入该证据链的系统探索不

应被写成已验证贡献。

P0 E3 之后, fusion 不再只是辅助诊断机制, 而是论文第二条实验证据线。它根据文本侧和音频侧 top-k 分数计算熵、质量分数和 audio bias, 再输出 w_{text} 与 w_{audio} 。该机制的价值在于真实退化下避免 audio-heavy fixed fusion 的脆弱性, 并把系统推向更稳定的中高文本权重工作区间。它的局限也很明确: 当文本与音频发生语义冲突时, 旧 Protocol-C 仍显示当前规则可能偏离更低误差的 TRR-only 结果。因此, 本文把 adaptive fusion 写成当前退化集合下的鲁棒机制, 不写成跨域或冲突场景下的通用最优策略。

第六章TMM 实验设计与评价方法

本章把当前实验协议改写为 TMM 期刊证据矩阵。核心原则是：每一个实验只服务一个可证伪命题，每一个主表数值都必须由原始输出、统计脚本和论文包中的具体位置共同支撑。P0 E2/E3 已由用户 double check 为真实、完整、正确的正式实验数据，并将主张从单一 TRR retrieval prior 升级为“TRR 表示优势 + 真实退化下 adaptive fusion 稳健机制”；若要达到最终 TMM 期刊论文强度，还必须把强基线公平性、TRR 消融、泄漏审计、感知评价边界、补充材料页数和 response letter 一致性同时纳入 gate。

表 6.1: TMM 期刊证据矩阵与 KaiMing 通过标准。

Gate	目标命题	最小证据集合	主要检查项	通过标准
T0 Scope	论文属于 TMM 范围	引言、相关工作、方法 framing	任务和贡献是否服务音频参数控制	不以通用 agent 或 demo 为核心贡献。
T1 Evidence	当前主证据可复核	P0 E2、P0 E3、听测、split audit	checksum、manifest、统计复现、artifact path	主表文件可由 manifest 定位。
T2 Baseline	排除弱基线解释	Wav2Vec、FeatureNN、CLAP、PaSST、PANNs；未完成 direct regression 显式标注	参数指标、Norm.L2 检验与配对样本	同 split、同 query、同 logger；未完成项不暗示 SOTA。
T3 Ablation	二阶段理统计是有效成分	mean pooling、Gram、层选择、归一化、top-k	主指标与运行成本	至少一个结构消融削弱主指标。
T4 Leakage	结果不来自近重复泄漏	exact path、hash、近邻、family split	重复率与严格 split 表现	严格 split 下结论方向保持，或降级 claim。
T5 Boundary	感知与鲁棒边界被披露	听测、P0 E3、旧 Protocol-C failure case	rater 元数据、真实退化、conflict failure	证据不足时限定为 proxy 与诊断。
T6 Package	主文、附录、答复与匿名位一致	paper、supplement、response、checklist、code/data	页数、warning、citation、证据追踪	claim、附录表、代码输出和答复一一对应。

表 6.1 是后续 TMM 修订的实验与提交包契约。该契约把当前最可辩护的研究对象压实为四个限定词：检索式、可执行、参数可编辑、证据可审计。凡是不能进入这个矩阵的探索，例如产品侧 UI、个性化记忆或端到端生成体验，都应保留在 future work 或系统背景中。

本报告采用三类协议口径。第一类是当前主证据协议，即 P0 E2/E3。P0 E2 基于外部 1267 条 guitar-effects benchmark drop-in，形成 204 条测试查询和 1063 条知识库记录，并在同一 split 上比较 TRR、Wav2Vec、FeatureNN、CLAP、PaSST 和 PANNs；P0 E3 复用该 split，对原始音频施加 AWGN、MP3、reverb 和 truncate 退化后重新编码。第二类是审计协议，即 resolved-audio-grouped Protocol-A，用于说明 legacy split 的 exact cross-split audio reuse 风险和更严格切分下的历史数值。第三类是诊断协议，即旧 211-query Protocol-C、Protocol-B 和 legacy retrieval report，用于分析历史边界而非主结论。

表 6.2: 实验协议、数据规模与证据状态。

协议或材料	测试数	知识库数	状态	本文用途
Protocol-A audio-grouped	204	1063	本地主统计与 per-query 结果存在	主证据, 论文主表口径。
Protocol-A legacy/strong	211	1056	本地结果存在, 但含 legacy split 风险	历史对照或诊断, 不与 204 口径混写。
P0 E3 real degradation	204	1063	用户已 double check 真实完整正确	Adaptive fusion robustness 主证据。
Protocol-C diagnostic	211	1056	本地统计与 per-query 结果存在	Fusion fallback 与 conflict failure 诊断。
Listening test	26 participants	910 ratings	统计报告存在	主观补充, 不作为严格胜负证据。
P0 E2	204	1063	用户已 double check 真实完整正确	Baseline matrix 主证据。
Protocol-B	211	1056	文件自标 deprecated	历史材料, 不进入主结论。

表 6.2 中最重要的设计选择是把 204 条 audio-grouped Protocol-A 固定为主文口径。旧 211-query 结果在数值上更好看, 例如 TRR 的 L2 为 0.3064, 但该切分的 audit 发现 16 条跨 split shared resolved audio paths 和 48 对近重复风险。严格切分的 TRR L2 变为 8.0467, 数值尺度明显不同, 却更适合作为提交面主证据。因此, 本文宁可使用较难、更保守的主表, 也不将 legacy 数值当作核心结论。

TMM 主文还需要把 baseline matrix 前置为 fairness contract, 而不是只在结果表中列出方法名。

表 6.3: Baseline matrix: 对比方法、指标与公平性约束。

方法	证据状态	共享协议	公平性约束	TMM 使用方式
TRR	主方法	P0 E2	缓存向量、同一 evaluator、同一 split	主表核心结果。
Wav2Vec	已评估	P0 E2	同 query set 与参数指标	音频嵌入基线。
FeatureNN	已评估	P0 E2	同 top-1 检索输出与同统计检验	工程特征基线。
CLAP	已评估	P0 E2	同 query set 与同统计检验	语义音频基线。
PaSST/PANNs	已评估	P0 E2	用户已 double check 真实完整正确	主表 baseline。
Direct regression / reranker	待复现	后续 runbook	未完成前不进主表	limitations 或补实验。

表 6.3 的约束意味着: CLAP、PaSST 与 PANNs 已经可以进入 P0 E2 主表; direct regression、learned reranker 与 Text2FX-style optimization 仍只能作为待复现项。

每个检索方法输出一个候选参数 JSON。参数距离按展开后的数值叶子计算 RMSE; 阈值准确率、召回、余弦相似度和模块一致性由公共 evaluator 实现。P0 E2 同时报告 raw L2 与 Norm.L2, 并以 per-query Norm.L2 做 Wilcoxon signed-rank 检验和 Holm correction。Resolved-audio-grouped Protocol-A 的 bootstrap confidence intervals 与 paired permutation tests 保留为 split audit 和历史对照, 不再替代 P0 主表。

P0 E3 的退化场景分别覆盖 AWGN、MP3、reverb 和 truncate, 并在退化后重新编码 TRR embedding。旧 Protocol-C 的 vague text、embedding-space noisy audio 和 modality conflict

仍只能说明 score-level fusion heuristic 的边界行为，不能替代 P0 E3 的真实退化证据，也不能证明系统已具备跨域鲁棒性。

第七章 TMM 可复现台账与证据包规范

本章把代码实现路径进一步约束为 TMM 可复现证据路径。TMM 期刊论文不能只依赖“某个脚本曾经跑出过表格”；它需要每个结果都能回答五个问题：使用了哪一次运行，运行时仓库处于什么状态，输入数据和 split 的 checksum 是什么，统计检验如何从原始 per-query 结果生成，以及该结果在主文、补充材料和 response letter 中被如何引用。Logger 的职责就是把这些问题变成强制字段。

表 7.1: TMM run logger 的最小字段规范。

字段	类型	角色	说明
run_id	string	主键	采用日期、实验编号、方法和短 hash 组成，所有 CSV/JSON/MD 共享。
submission_gate	enum	监督阶段	取值如 T1-evidence-freeze、T2-baseline、T3-ablation、T6-package。
git_commit / git_dirty	string/bool	代码状态	记录 HEAD、branch、未提交变更摘要；dirty run 只能作探索，不能直接进主表。
command / env	string/object	复现入口	保存完整命令、Python 版本、关键依赖版本、设备信息。
dataset_checksum	string	数据快照	指向 dataset manifest、split manifest 和原始 JSON/CSV checksum。
split_id	string	协议边界	明确 204 audio-grouped、legacy 211 或更严格 family split。
query_count / kb_count	integer	规模审计	防止不同口径的样本规模被混入同一主表。
method_config	object	方法定义	保存 retriever、embedding、normalization、top-k、seed、ablation flags。
metrics / stats	object	统计结果	保存均值、CI、paired permutation、Holm correction 和有效样本交集。
artifacts	list	证据索引	列出 per-query CSV、summary JSON、stats MD、stderr/stdout 和 checksum。
paper_links	list	投稿映射	列出 main paper、supplement、response letter 与 checklist 中引用该结果的位置。
failure_flags	list	负面证据	记录缺失缓存、跳过样本、异常输入、退化场景失败类型。

表 7.1 是后续实验代码需要满足的最小审计接口。它的主要作用是让论文表格、附录统计和匿名代码包共享同一证据主键。

TMM 修订还需要一张可复现性表 (reproducibility table)，把运行字段映射到论文审稿时可检查的最小项。

表 7.2: 可复现性表: random seed、数据划分、配置、硬件与运行命令。

维度	当前状态	必填字段	TMM gate
随机种子	部分脚本需补登记	seed、hash、统计重采样次数	进入主表前冻结。
数据划分	204 audio-grouped 已定义	split id、query count、kb count、checksum	不同 split 不混写。
方法配置	TRR 与基线配置需集中化	retriever、embedding、normalization、top-k	同表方法共享 evaluator。
硬件环境	当前报告未统一记录	device、Python、依赖版本、缓存状态	匿名包 README 必填。
运行命令	旧产物命令不完整	command、cwd、env、stdout/stderr	无命令不进主结果。
论文映射	TMM 包需新增	main table、supplement、response、checklist	claim-to-evidence 一一对应。

表 7.2 将 TMM 复现要求转化为主表进入条件: 没有 seed、split、配置、硬件和命令的结果, 不能进入主文核心 claim。

建议将每次运行归入 `Experiments/tmm/runs/` 下的独立 `run_id` 子目录, 最小文件包括运行描述、per-query 结果、统计摘要、校验和、日志与 paper links。本报告不声称该目录已经完全实现; 它是从当前 evidence boundary 和 TMM reproducible research 要求推导出的 design intent。后续实现时, 旧的 Protocol-A/Protocol-C 产物可以被迁移或注册到同一 schema, 而不需要重写历史结果。

KaiMing 对 logger 的验收标准很简单: 任何进入主文的表格行, 都必须能反查到唯一运行主键; 任何显著性结论, 都必须能反查到配对样本交集; 任何缺失输出或 dirty run, 都必须在表注或局限中被披露。任何 response letter 的答复, 也必须能反查到主文或补充材料中的具体表、图或段落。若做不到这一点, 该结果只能进入探索记录或附录待复现清单。

代码库中存在产品链路与实验链路两套路径。产品链路从用户文本和可选音频出发, 通过 DeepSeek 解析风格与参数, 经 `import_params.json` 传入 JUCE 插件, 再由插件加载参数和音频并离线渲染。该链路说明 Audio-Agent 具备可执行插件控制的工程背景, 但本文不把它作为主实验结果来源, 因为主实验没有评价完整插件输出音频质量。

实验链路更适合作为论文证据。数据加载由 common dataset loader 负责, 优先读取外部 1267 条数据集 JSON, 再回退到 repo 内 JSON 或 SQLite 合并。TRR 检索由 common TRR adapter 实现, 优先使用缓存向量。直接检索比较与 Protocol-C 分别由 AblationStudies 下的 comparison 与 robustness 脚本驱动, 评价指标由公共 evaluator 计算。




图 7.1: 实验证据生成路径。论文主结论应回到可复核的 CSV、JSON、Markdown 统计产物，避免依赖未验证的工程愿景。

图 7.1 对应当前最可靠的复现路径。对于 P0 E2，复核者应从已确认真实完整正确的 E2 summary 与 E2 stats 口径开始，确认样本规模、指标定义和 Norm.L2 配对统计。

对于 P0 E3，复核者应检查 `e3_overall_summary.csv`、`e3_summary.csv`、退化配置和 oracle relevance 定义。对于旧 Protocol-A/Protocol-C，复核者仍可使用本地 audio-grouped CSV/JSON 与 diagnostic stats 追溯历史数值，但不应把旧诊断替代 P0 主结果。

当前代码中还存在一些不应被误写为主证据的部分。实验侧 Text-RAG 实际更接近 deterministic keyword overlap；Protocol-B 已经被标注为 deprecated；E0 合成音频管线仍有缺失音频记录。因此，本文在结论中使用“under the current held-out protocol”、“cached TRR representation”和“currently evaluated baselines”等限定语。

第八章 证据资产与归档结构

本次报告生成前，实验材料已经被整理到 AblationStudies 的 organized experiment data 子目录。该目录承担当前工作区可见材料的证据快照角色，不承担新的实验运行职责。它包含 manifest、checksums、P0 报告与脚本、Protocol A/B/C 结果、fusion beta sweep 以及 legacy retrieval report。所有归档文件都有 checksum，便于后续判断内容是否被改动。

证据资产评价的关键是文件能够支持什么强度的结论。P0 E2/E3 的报告数值已经由用户 double check 为真实、完整、正确，可支撑本轮论文主结果。Protocol-A audio-grouped 的 CSV、JSON 和 Markdown 统计报告能够支撑 split audit 与历史对照；旧 Protocol-C 的 CSV/JSON/MD 能支撑 fallback 与 conflict failure 诊断；listening test 的统计报告能支撑主观补充分析；Protocol-B 和 legacy report 明确不应进入主证据链。

表 8.1: 主要证据资产、来源状态与论文用途。

资产组	来源状态	论文用途
protocolA_audio_grouped_*	workspace untracked	主证据；严格切分下 TRR 对比。
protocolA_*_with_clap*	workspace untracked	诊断或补充；211-query 口径不得混入主表。
protocolC_*	workspace ignored	辅助诊断；说明 fusion fallback 与 conflict failure。
results_report.md	workspace file	听测补充；说明主观评分与统计限制。
P0_Experiments_Report.md	verified experimental data	P0 E2/E3 主结果来源。
protocolB_*	workspace ignored	deprecated 历史材料。
retrieval_comparison_report.md	tracked legacy	追溯早期叙事，不作为 TMM 主证据。

表 8.1 现在解释的是证据使用边界，而不是 P0 结果是否可写入论文。用户已确认 P0 原始产物真实、完整、正确，因此 PaSST、PANNs 和真实退化 E3 数值可以进入本轮论文主张。

为了让后续写作不再次漂移，建议将证据资产冻结为三个目录层级。第一层是 P0 主证据目录，包含 P0 E2/E3 的正式结果表与统计口径。第二层是审计与补充目录，包含 resolved-audio-grouped Protocol-A、旧 Protocol-C diagnostic 和 listening test。

第三层是历史与待补目录，包含 Protocol-B、legacy retrieval report、direct regression 和 future reranker。这个结构有助于在写作中持续区分已确认正式实验数据、repo-observed fact 与 design intent。

第九章 当前基线结果与统计证据

主实验结果见表 9.1。本轮写作将 P0 E2 结果提升为 TMM 主文的 baseline matrix：同一 204-query / 1063-KB 协议下，TRR 与 Wav2Vec、FeatureNN、CLAP、PaSST 和 PANNs 对比。用户已 double check P0 原始数据真实、完整、正确，因此这些数值直接作为正式实验数据写入。

面向 TMM 修订，表 9.1 的角色应升级为 objective core table。它可以支撑“TRR 在当前 P0 已评估检索基线中更强”，但不能支撑“TRR 是最先进通用音频表示”或“系统完成端到端自动音频制作”。若主文、supplement 或 response letter 使用该表，必须同时标注 204-query split、metric definition、Norm.L2 统计检验口径和小效应量边界。

表 9.1: P0 Protocol-A 主结果。L2 与 Norm.L2 越低越好，其余指标越高越好。

Method	n	L2	Norm.L2	Acc@0.1	Recall	Cosine	Module
TRR	204	8.7287	0.1881	0.5766	0.5404	0.8415	0.8297
Wav2Vec	204	22.5174	0.2400	0.5015	0.4648	0.5642	0.7423
FeatureNN	204	17.9391	0.2236	0.5264	0.4779	0.6030	0.7544
CLAP	204	16.1257	0.2298	0.5389	0.4922	0.6531	0.7837
PaSST	204	18.2860	0.2132	0.5422	0.5001	0.6192	0.7960
PANNs	204	21.0269	0.2260	0.5090	0.4759	0.5826	0.7606

表 9.2 汇总 TRR 相对各 baseline 的 paired significance。P0 统计检验基于 per-query Norm.L2，而不是同时覆盖所有指标。所有 baseline 在 Holm 校正后均拒绝原假设；但 Cohen’s d 较小，因此应解释为统计可靠、幅度适中的优势。

表 9.2: P0 Protocol-A 中 TRR 相对各 baseline 的 Norm.L2 统计检验。

Baseline	n	p -value	Cohen's d	Holm reject
Wav2Vec	204	1.564e-07	-0.2101	Yes
FeatureNN	204	9.523e-05	-0.1380	Yes
CLAP	204	4.476e-04	-0.2189	Yes
PaSST	204	1.254e-03	-0.0980	Yes
PANNs	204	2.122e-05	-0.1528	Yes

表 9.1 与表 9.2 共同支持一个窄而强的结论：在当前 P0 baseline matrix 中，TRR 是最强的参数对齐 retrieval prior。该结论不能外推为“TRR 是通用最优音频表示”。

外推边界来自三项事实。数据集是 guitar-effects 领域数据，不覆盖全部音频任务。评价指标是参数空间 operational metrics，不能直接替代听感距离。PaSST 与 PANNs 已经进入 P0 E2；直接参数回归、learned reranker 和跨域基线仍未完成。

P0 E3 的结果见表 9.3。该协议对原始音频施加 AWGN、MP3、reverb 和 truncate 退化，再重新编码为 TRR embedding，并复用 P0 E2 的 204-query test split。结果显示，audio-heavy 的 fixed fusion a0.30 明显不稳定；adaptive fusion 在总体 L2、Acc@0.1、MRR 和 NDCG@5 上略优于 fixed a0.50 / a0.70，但差距不应被写成压倒性胜利。

表 9.3: P0 Protocol-C 真实退化鲁棒性结果。

Method	α	L2	Acc@0.1	MRR	NDCG@5
fixed fusion a0.30	0.3000	29.2322	0.4846	0.4095	0.3723
fixed fusion a0.50	0.5000	20.5551	0.6085	0.5607	0.5528
fixed fusion a0.70	0.7000	20.1868	0.6104	0.5652	0.5551
adaptive fusion	0.5980	20.1491	0.6121	0.5654	0.5566

听测结果见表 9.4。Trials 2-5 中，TRR-based system 的主观评分高于 manual baseline；

Trials 6–10 中，MusicGen 与 TRR-based system 的差异没有达到统计显著。由于该实验没有显式低质量 anchor，也缺少设备、参与者专业程度和人工基线时间预算等元数据，本文将其解释为 workflow relevance 的主观背景，不将其写成系统优于人工或优于生成模型的强结论。

表 9.4: Multiple-stimulus listening test 摘要。原始日志标签 HCAP 在论文叙述中对应 TRR-based system。

Block	Comparison	n	Mean(A-B)	rbc	p (Holm)
Trials 2–5	reference vs TRR-based system	26	13.78	0.860	0.00015
Trials 2–5	TRR-based system vs manual	26	19.83	1.000	0.00015
Trials 6–10	reference vs TRR-based system	26	46.71	0.994	0.00015
Trials 6–10	MusicGen vs TRR-based system	24	-1.10	0.067	0.7797

综合来看,当前证据支持的论文叙事应当升级为双核心:P0 E2 证明 TRR 在更完整 baseline matrix 下仍是最强 retrieval prior; P0 E3 证明真实退化下 fusion design 是鲁棒性的关键, adaptive fusion 比 audio-heavy fixed fusion 更接近稳定工作区间;听测说明用户感知背景。TMM 论文包中,这三类结果应分工明确: P0 E2 进入主文结果表; P0 E3 进入 robustness-and-fusion 结果段落; 听测进入补充感知证据和局限讨论。

未完成的 direct regression、learned reranker、跨域真实退化和更严格听测仍只能出现在 limitations、future work 或 response 的未完成说明中，不能进入主结论。

第十章项目进度与 TMM 提交包收束计划

截至 2026-05-02，本报告对应的仓库状态是一个实验材料进一步增强、但 submission hygiene 尚未完全收束的 TMM 修订工作区。已经完成的部分包括：用户确认 P0 E2/E3 原始产物真实、完整、正确；P0 E2 已补齐 TRR、Wav2Vec、FeatureNN、CLAP、PaSST 和 PANNs baseline matrix；P0 E3 已补齐真实退化下 adaptive-vs-fixed fusion 结果；听测统计有本地可读产物；Experiments/tmm 下已有 split audit、leakage audit 和相关测试；TMM response、revision checklist、main paper 与 supplementary 已按双核心贡献方向更新。尚未完成的部分包括：统一 TMM run logger 尚未实现；主文与 supplement 仍需按 TMM/SPS 页数和 warning gate 检查；部分仓库路径和结果资产仍需完成版本控制卫生。

表 10.1: 当前项目进度与证据状态。

事项	当前状态	下一步
报告工作区	正在从 NeurIPS 监督报告改为 TMM 证据监督报告	完成全局术语、gate 和 sources 同步。
P0 E2 主证据	204-query baseline matrix 已确认	冻结为 TMM 主文 objective core table。
主结果统计表	已补 mean [95% CI] 与 Holm-corrected paired tests	与 TMM run id、checksum 和 paper links 绑定。
P0 E3 real degradation	用户已 double check 真实完整正确	作为 adaptive fusion 鲁棒性主证据，但不写成跨域鲁棒性。
听测统计	26 participants / 910 ratings 报告存在	继续作为主观补充，披露 anchor 与 metadata 限制。
TMM 论文包	main / supplement / response / checklist 均存在	检查页数、warning、引用、response-to-evidence trace。
P0 E2/E3 结果状态	已确认真实完整正确	直接进入论文主结果，保持小效应量与单域边界。
Protocol-B 与 legacy report	已降级为历史材料	不进入 TMM 主论文证据链。

表 10.2: TMM 提交包收束节奏。

阶段	KaiMing gate	预期产物	不通过时的处理
P0	Scope migration	TMM title、goal、outline、gate、sources 与 report sections 全局一致	不进入论文包修订，先修报告真源。
P1	Evidence freeze	canonical artifacts、checksums、204 split lock、paper links schema	不写新 claim，先修证据台账。
P2	Submission hygiene	main paper 页数、supplement 页数、LaTeX warning、citation、response package	不提交：先修 formatting 与 response trace。
P3	Baseline / ablation closure	PaSST/PANNs 已进入 P0；direct regression、reranker 与 TRR 消融表仍待补	若证据缺失，主文保守写作，不写通用 SOTA 或 mechanism-strong claim。
P4	感知与鲁棒边界	听测局限、P0 E3 真实退化、旧 Protocol-C conflict failure case	真实退化只限定在当前条件集合下。
P5	最终提交包冻结	匿名代码包、revision checklist、response ledger	未通过则只形成内部技术报告。

表 10.1 中最需要优先处理的是主证据冻结和提交包卫生。若目标是正式投稿，建议把 P0

E2、P0 E3、listening test 和 split audit 纳入同一论文证据索引，并在 README 或 response checklist 中记录生成命令、数据集快照、统计方法和局限边界。P0 中的 PaSST/PANNs 与真实退化 E3 结果已经可以进入论文主结果。表 10.2 给出的节奏属于监督计划；每个阶段结束必须用 PDF 编译报告和 response checklist 更新本章。

当前报告本身也应视为 single-source working report。它已经根据现有代码和实验产物生成正文，并开始承担 supervisor ledger 的职责，但仍需要人工做三类审阅。

第一类是科学审阅，确认是否接受“TRR 是当前已评估 retrieval prior 中最强 + adaptive fusion 是当前真实退化集合下更稳健机制”这一双核心主张。第二类是证据审阅，确认 P0 E2/E3 是否作为唯一主文核心口径，并将旧 211 口径与 audio-grouped 历史表全部移入附录或审计说明。第三类是投稿审阅，确认 TMM 主文、supplement、response letter、匿名代码包和 evidence ledger 是否满足期刊审稿标准。

第十一章 KaiMing Gate: TMM 风险、验收与论文写作前置条件

本文的主要结论仍然保守，但主证据已比上一版更强。P0 E2 表明 TRR 在当前 guitar-effects、204-query、retrieval-only benchmark 上，是 Wav2Vec、FeatureNN、CLAP、PaSST 和 PANNs 中参数对齐最强的 retrieval prior；P0 E3 表明真实音频退化下，adaptive fusion 明显优于 audio-heavy fixed fusion，并接近中高文本权重的稳定工作区间。该结论足以构成一篇围绕 retrieval-grounded editable audio effect control 与 real-degradation fusion robustness 的 TMM 方法与实验证据报告，但不足以支撑通用音频表示、端到端主观质量或完整自动化音频系统的强 claim。

KaiMing gate 用于防止 TMM 论文在证据尚未闭合时提前固化。当前阶段允许修订 abstract、method skeleton、experiment checklist、supplement 和 response letter；不允许锁定强 novelty claim、SOTA-level conclusion 或未绑定 artifact 的 reviewer response。主论文启动条件应由表 11.1 控制。

表 11.1: KaiMing gate 与 TMM 论文写作前置条件。

Gate	必须通过的证据	失败时的论文处理	状态
范围门	TMM scope、主问题、输出对象和贡献边界已冻结	回到引言与相关工作，不写泛化 agent claim	正在迁移。
基线门	CLAP、PaSST、PANNs 已纳入；直接回归和 Text2FX 式基线状态被标注	主表不能声称通用 SOTA 级优势	部分完成。
消融门	二阶纹理、层选择、归一化和 top-k 有可解释贡献	方法贡献降级为经验检索特征	待实验。
泄漏门	exact duplicate、near duplicate 和 family split 风险已审计	降低 claim 或更换主协议	部分完成。
鲁棒门	P0 E3 已覆盖 AWGN、MP3、reverb、truncate；conflict 场景仍属旧诊断	鲁棒性写为当前退化集合下的 fusion 机制证据	部分完成。
感知门	参数指标与听感评分关系已估计，或明确相关性不足	参数指标限定为 controllability proxy	待补强。
复现门	logger、checksum、run scripts、匿名包和 checklist 对齐	只能作为内部报告或草稿	待实现。
提交门	主文、附录、答复、checklist 和 LaTeX warning 通过 TMM/SPS 检查	不进入正式提交	待全量检查。

第一个局限是数据域。当前 benchmark 主要围绕吉他效果预设展开，参数结构也绑定于特定效果链。TRR 对该域有效，并不自动意味着它对鼓组、人声、混音母带或开放世界音频编辑同样有效。第二个局限是指标。Param. Dist.、Acc@0.1、Recall、Cosine 和 Module 都是参数空间指标，不能完全替代听感距离。第三个局限是协议。严格 split 已消除 exact resolved-audio reuse，但 near-duplicate 风险仍需更强审计。第四个局限是工程证据。产品链路存在，但主实验没有直接评价完整插件输出音频。

第二个需要明确的风险是融合边界。P0 E3 说明 adaptive fusion 在 AWGN、MP3、reverb 和 truncate 退化下接近稳定工作区间，但它不是每个 condition / 每个 metric 的压倒性赢家。旧 Protocol-C conflict 场景中的 Fusion L2=4.5259 远高于 TRR-only 的 0.2970，仍说明当前融合规则无法可靠处理相互矛盾的文本与音频输入。若后续要扩展融合主张，必须新增独立协议，定义冲突输入、真实退化、失败类型和统计检验。

表 11.2: 主张、证据与允许措辞矩阵。

主张	证据状态	允许措辞
TRR 优于当前已评估检索基线	P0 E2 支撑	可以作为主结论。
TRR 是通用最优音频表示	无跨域证据	不应声称。
Adaptive fusion 具备真实退化稳健性	P0 E3 支撑	可作为主结论的第二部分。
Adaptive fusion 全面优于所有固定策略	per-condition 表不支持	不应声称。
TRR-based system 有主观感知价值	听测补充支持	可保守表述为主观背景。
系统严格优于人工调参或 MusicGen	元数据与统计边界不足	不应声称。
P0 PaSST/PANNs 已正式验证	用户已 double check 真实完整正确	可以进入论文主结果。

表 11.2 是本文最终结论的约束条件。后续交付应按三个优先级推进。首先，冻结主证据：将 P0 E2、P0 E3 和 listening test 作为 canonical evidence，并明确各自的统计口径、数据集快照和局限边界。其次，收束 TMM 论文包：主文、supplement、response letter 和 revision checklist 必须引用同一组证据，并清理页数、warning、citation 与匿名包问题。最后，若要主张跨域鲁棒性或端到端听感优势，还需要新增独立协议。

在当前证据条件下，最合适的论文式结论是：TRR 将深层音频特征的二阶纹理统计用于可执行音频效果参数检索，在当前 guitar-effects 检索基准中，相比 Wav2Vec、FeatureNN、CLAP、PaSST 和 PANNs 等已评估基线表现出更好的参数对齐；同时，真实退化下的 adaptive fusion 比 audio-heavy fixed fusion 更稳健，并接近中高文本权重的稳定工作区间。该结论比上一版更强，但仍窄而可审计。

因此，本报告对下一阶段的监督结论是：先完成 canonical evidence freeze 和 submission hygiene，再决定是否投入新的 direct regression、reranker 或跨域消融实验。当表 11.1 至少通过 scope、baseline honesty、leakage、reproducibility 和 submission hygiene 五项后，才应进入 TMM 主文定稿。若短期内无法通过 ablation 或跨域 gate，项目仍可以形成严谨的 TMM revision package，但主张必须保持为“当前已评估检索基线下的 texture-aware retrieval prior + 当前真实退化集合下的 adaptive fusion robustness”，不得升级为通用 SOTA 或完整系统胜负结论。